

基于网络模型的心理学研究

主讲人：杜新楷

自我介绍

- 背景

- Modum Bad 精神科医院
- 奥斯陆大学博士生

- 研究兴趣

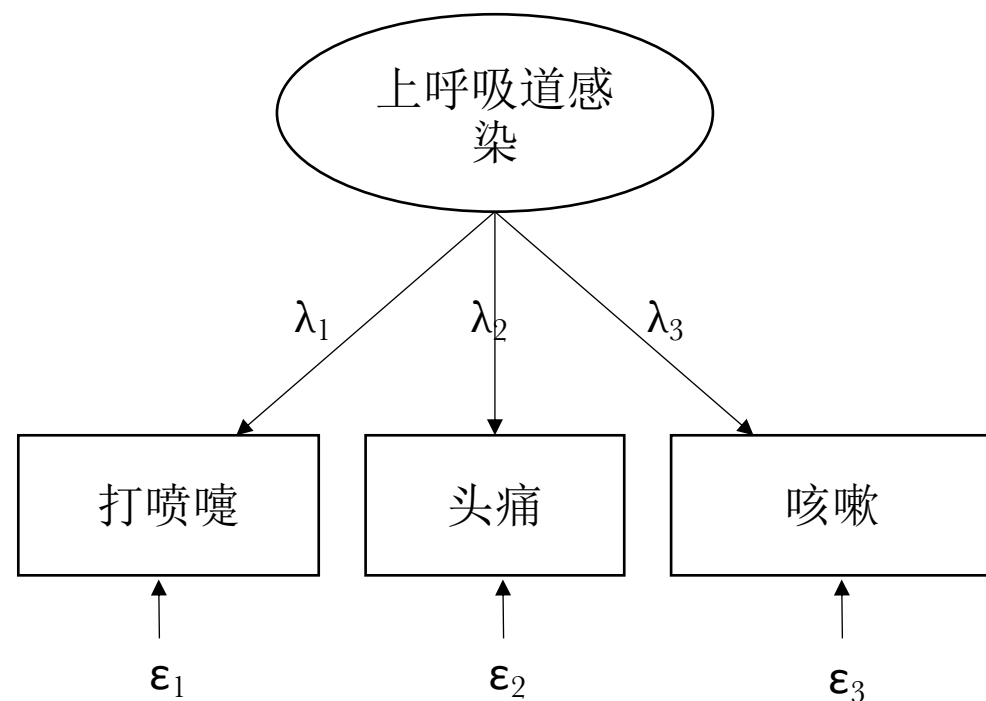
- 心理测量(psychometrics)
- 时间序列和面板数据分析(time-series and panel data analysis)
 - 动态网络的估计(estimation), 评估(evaluation)和比较(comparison)
- 在精神疾病分析中的运用

今天

- 背景
 - 基于潜变量模型的心理学研究
 - 为什么要使用网络模型
- 基于网络的心理学理论
- 网络模型的估计
 - 有向无环图Directed Acyclic Graph (DAG)
 - 高斯图模型Gaussian Graphical Model (GGM)
- 网络模型的模型选择
- 结语：网络模型的发展下潜变量的意义

基于潜变量的心理学研究

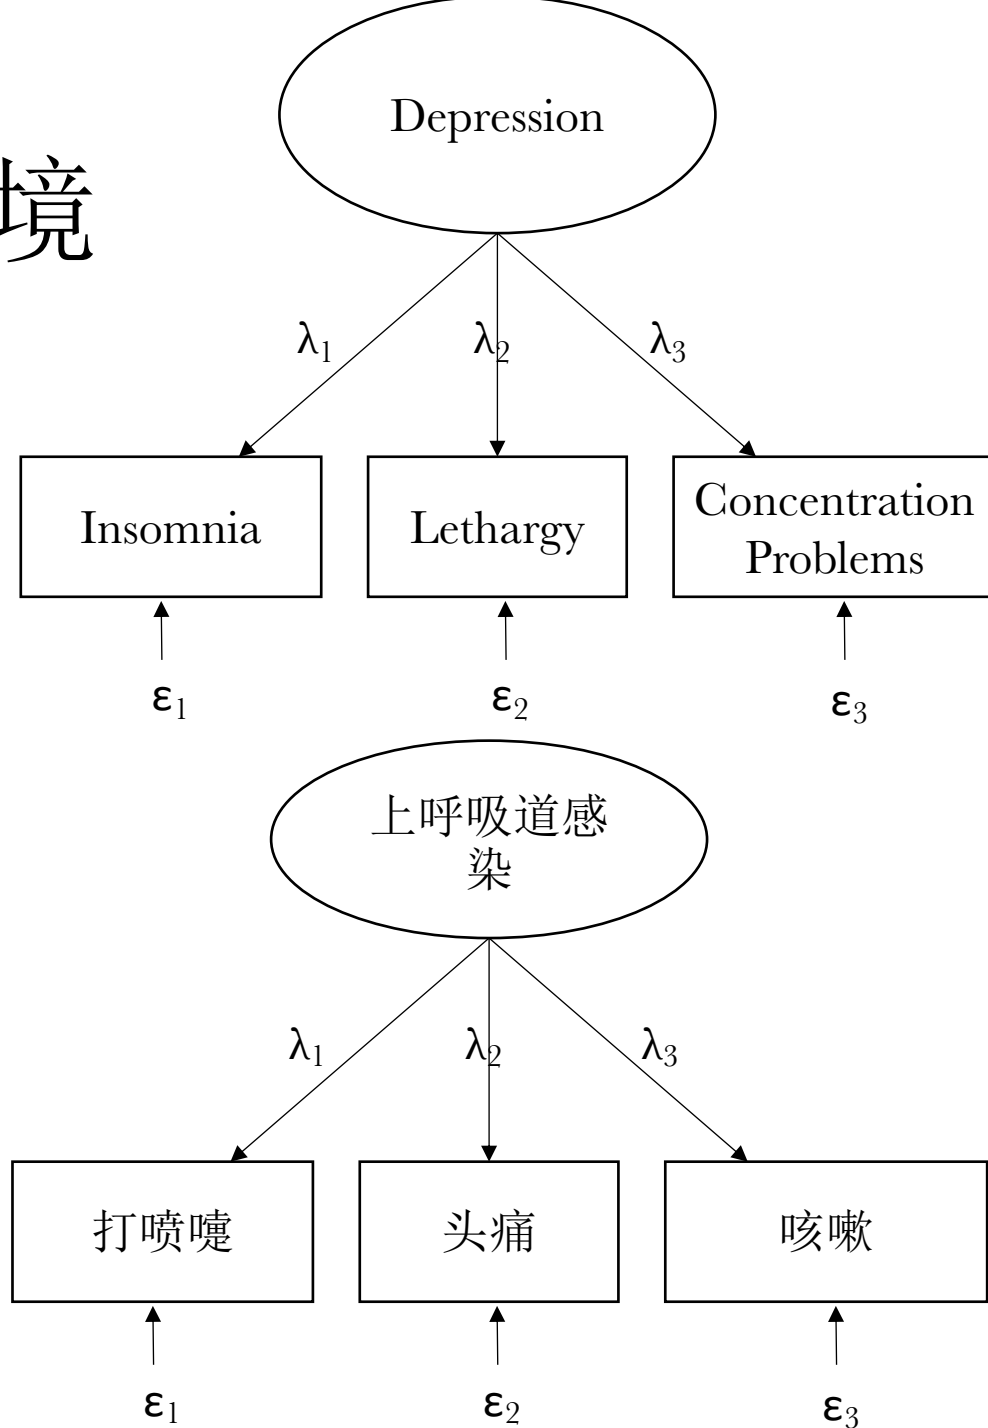
- 心理学一个很稳定的现象是特征之间的相关
 - g factor; positive manifold
 - comorbidity
- 使用共因解释可观测特征之间的相关，可观测特征是潜变量的结果
- 可观测特征之间的相关是潜变量造成的，控制潜变量后可观测特征之间的相关消失
 - 共因原则
- 对可观测特征的干预无法改变潜变量的值
 - 止痛药，止咳药都无法治感冒
 - 抗病毒 / 消炎 / 其他原因



潜变量模型在心理学的困境

- 研究概念而难以找到客观实体
- 可观测特征之间实际存在因果关系

➤ 睡不着 → 没精神 → 注意力不集中 → 自责




基于网络的心理学视角

- 可观测特征之间的关系是有意义的，对可观测特征的干预也是有效果的
 - 睡不着→没精神→注意力不集中→自责
 - 睡眠的改善可以显著改善抑郁
 - 喜欢与人交流→参与社交场合→朋友多
 - 帮助重建交流的勇气和完善沟通模式 鼓励尝试 可以改善社交状况
- 探索可观测特征之间的因果，关注可观测特征之间的相互作用
- 复杂系统的视角
 - 心理学现象是可观测特征之间相互作用的浮现(emergence)
 - 特征 → 心理学现象而不是现象 → 特征

如何寻找可观测特征间的因果关系？


- d-separation rule
 - Infer causation from conditional relations
 - Three causal prototypes
 - 共因 Common cause
 - 链 Chain (mediation)
 - 对撞因子 Collider



Judea Pearl (1936 -)

d-separation


confounding
Common Cause



Example:
Village Size (B)
causes babies (A)
and storks (C)

CI:
 $A \not\perp C$
 $A \perp C | B$


mediation
Chain



Example:
Smoking (A) causes
tar (B) causes
cancer (C)

CI:
 $A \not\perp C$
 $A \perp C | B$

Collider




Example:
Firing squad (A &
C) shoot prisoner
(B)

CI:
 $A \perp C$
 $A \not\perp C | B$


DAG (贝叶斯网络)

- 寻找变量间的因果图式并拼接
 - 通过collider来识别因果的方向
- E.g., 使用bnlearn
 - PC-algorithm, hill-climbing, grow-shrink, hybrid
 - Bootstrap + thresholding or model averaging to account for uncertainty
 - 估计方法结果相似
 - Briganti, G., Scutari, M., & McNally, R. J. (2023). A tutorial on bayesian networks for psychopathology researchers. *Psychological Methods*, 28(4), 947–961.
<https://doi.org/10.1037/met0000479>



DAG (贝叶斯网络)


- 贝叶斯网络的问题
 - 引入双向因果会导致模型无法识别
 - 必须引入无环假设，对探索性研究不利




DAG (贝叶斯网络)


- 贝叶斯网络的问题

- 必须引入无环假设，对探索性研究不利
- 等价模型
 - 只能通过collider确定因果方向
 - 剩下的完全无法统计上区分
 - 数量随节点增多指数增长
 - 通过理论区分难度同样很高
 - 如果目的是理论验证，更加糟心...



Equivalent?





高斯图模型 (GGM)

- 无向网络

- 使用偏相关矩阵代表网络 (这也是PC-algorithm的起点)
- 放弃因果的方向
- 模型有唯一解, 无等价模型问题
- 没有无环假设, 适合探索性研究

- 马克夫随机场(Markov random field)

- Markov property
 - Any two nodes / sets of nodes that are not connected on the graph are conditionally independent given other sets of nodes in the graph



- The MRF model:

- Concentration – Fatigue – Insomnia

- Is equivalent to three causal structures:

1. Concentration \rightarrow Fatigue \rightarrow Insomnia
2. Concentration \leftarrow Fatigue \rightarrow Insomnia
3. Concentration \leftarrow Fatigue \leftarrow Insomnia

易辛模型 Ising model



易辛模型

- FYI: 与IRT模型等价（可以复现同样的数据，无需潜变量假设）
 - Marsman, M., Borsboom, D., Kruis, J., Epskamp, S., van Bork, R., Waldorp, L. J., Maas, H. L. J. van der, & Maris, G. (2018). An Introduction to Network Psychometrics: Relating Ising Network Models to Item Response Theory Models. *Multivariate Behavioral Research*, 53(1), 15–35. <https://doi.org/10/gfj8tt>

心理网络的估计

高斯图模型

- Multivariate estimation 多元估计
 - 同时估计所有参数 (edge weights)
 - Typically rely on (pseudo) likelihood
 - E.g., qgraph, psychometrics, BGGM, glasso, huge
- Univariate (nodewise) estimation 一元 (单节点) 估计
 - 多个多元回归, 一次使用一个node作为DV
 - And / or rule
 - 结果取平均数
 - Connection between β and partial correlation (Meinshausen & Bühlmann, 2006)

多元估计

- 最大似然法


- 找到能够最大化数据似然的参数集合
- 拟合函数(的对数)一阶导数为0的时候
- GGM

- 当数据遵循方差矩阵为 Σ 的多元正态分布时，我们可以得到拟合函数为

- $\mathbf{K} = \Sigma^{-1}$

$$f(\mathbf{y}) = \frac{1}{\sqrt{(2\pi)^k |\mathbf{K}|^{-1}}} e^{-\frac{1}{2}(\mathbf{y} - \boldsymbol{\mu})^T \mathbf{K}(\mathbf{y} - \boldsymbol{\mu})}$$

$$\Sigma = \Delta(\mathbf{I} - \Omega)^{-1}\Delta$$





多元估计


- 最大似然法

- 优点

- Full information maximum likelihood可以处理缺失数据，无需删除样本
 - 不需要先验分布



多元估计



- 贝叶斯估计

- 使用MCMC对参数的后验分布取样来得到后验分布

$$f(\boldsymbol{\theta} \mid \mathbf{y}) \propto f(\mathbf{y} \mid \boldsymbol{\theta})f(\boldsymbol{\theta})$$

- 优点

- 很快


- 可以使用先验分布

- 运用贝叶斯进行多样的假设检验

- 很多教程


- <https://donaldrwilliams.github.io/BGGM/>

一元估计




$$y_1 = \tau_1 + \gamma_{12}y_2 + \gamma_{13}y_3 + \gamma_{14}y_4 + \varepsilon_1$$

一元估计




Note: 此处回归系数标记有误 应为 γ

一元估计




一元估计



一元估计

- AND / OR rule
 - OR-rule 取平均数
 - AND-rule 该连结的所有估计都不为0时取平均数，任一估计为0则该连结设置为0



Time for some coding

- Open R and install bootnet, psychometrics, BGGM, and qgraph


Time for some coding

- 更多教程：
 - R包手册
 - R包官网
 - 作者个人主页
 - R包如果发表在Journal of statistical software上也会有教程（e.g., mgm）

心理网络的模型选择

模型选择


最简单的独立模型



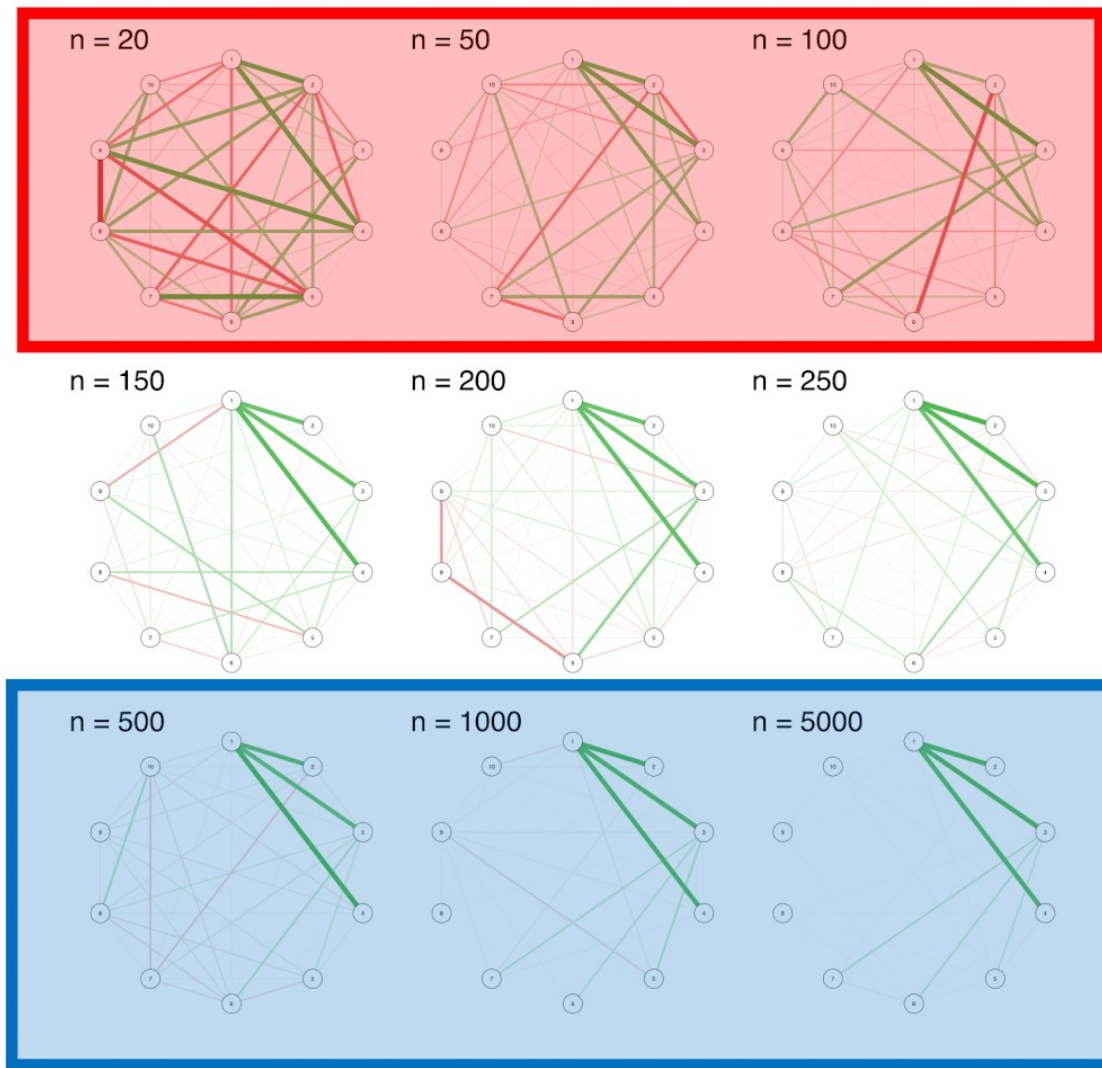
最复杂的饱和模型

模型选择

模型选择的缺失极易导致
虚假结果false discovery




True model



Estimated models at different N


模型选择

- 奥卡姆剃刀
 - 在拟合相似的模型中选择最简单的
- 在网络估计中，模型选择是必须的
 - 简化模型，留下有解释意义的参数
 - At least, so we hope
- 模型选择的方式有许多种，根据具体情况选择



模型选择的方式

- 阈值法(thresholding)
- 剪枝法(pruning)
- 正则法(regularization)
- 模型搜索(model search)



阈值&剪枝法

- 阈值法
 - 隐藏不符合标准的连结(e.g., $\alpha > .05$), 但不重新估计模型
- 剪枝法
 - 预测饱和模型(最复杂模型)后把不符合标准(e.g., $\alpha > .05$)的连结设置为0后重新估计模型(可反复)
- 显著性可以是 (bootstrapped) p值, false discovery rates(FDR), 或者贝叶斯因子
- 在一元估计中的AND / OR - rule也是模型选择

Time for coding

阈值&剪枝法

- 优点
 - 快速
 - 固定的假阳性率
 - 非偏估计
 - 比较保守
- 缺点
 - 阈值法不选择模型
 - 小样本时不稳定

正则法

- Lasso regularization

- 多元估计

- 最大化被惩罚的似然(maximize the penalized likelihood)

- λ $\log \det(\mathbf{K}) - \text{trace}(\mathbf{S}\mathbf{K}) - \lambda \sum_{\langle i,j \rangle} |\kappa_{ij}|$

- 使用EBIC来选择 λ, γ 越大模型复杂度惩罚越大

- EBIC = $-2L + E \log(N) + 4\gamma E \log(P)$
 - 一元估计

- 在每一个multiple regression的时候使用lasso

$$\min_{\beta \in \mathbb{R}^p} \left\{ \frac{1}{N} \|y - X\beta\|_2^2 + \lambda \|\beta\|_1 \right\}$$

- 也可以使用交叉验证法(cross-validation)

- 推荐阅读mgm的manual


Coding time

正则法

- 优点
 - 快速
 - 非常适合小样本
 - 结果清晰
- 缺点
 - 大样本下表现差
 - 依赖稀疏假设
 - 没有固定的假阳性率

模型搜索

- 最强大的方法
 - 也最慢
- 使用无正则的（最大似然）估计不停地调整并重新估计模型，直到最优解
- 较简单的
 - Step-up approach in psychometrics
- 较复杂的
 - ggmModSelect in qgraph
 - modelsearch in psychometrics



psychonetrics: step-up

- 从空模型(或剪枝过的模型)开始
- 添加modification index(MI)最大的edge
- 重新估计模型
- 查看MI并再添加MI最大的edge
- 重复直到BIC不再下降

```
mod <- ggm(bfi_na.rm, omega = "empty") %>%  
runmodel %>% stepup  
net <- getmatrix(mod, "omega")
```

```
mod <- ggm(bfiSub) %>% runmodel %>%  
prune(alpha = 0.01) %>% stepup  
net <- getmatrix(mod, "omega")
```

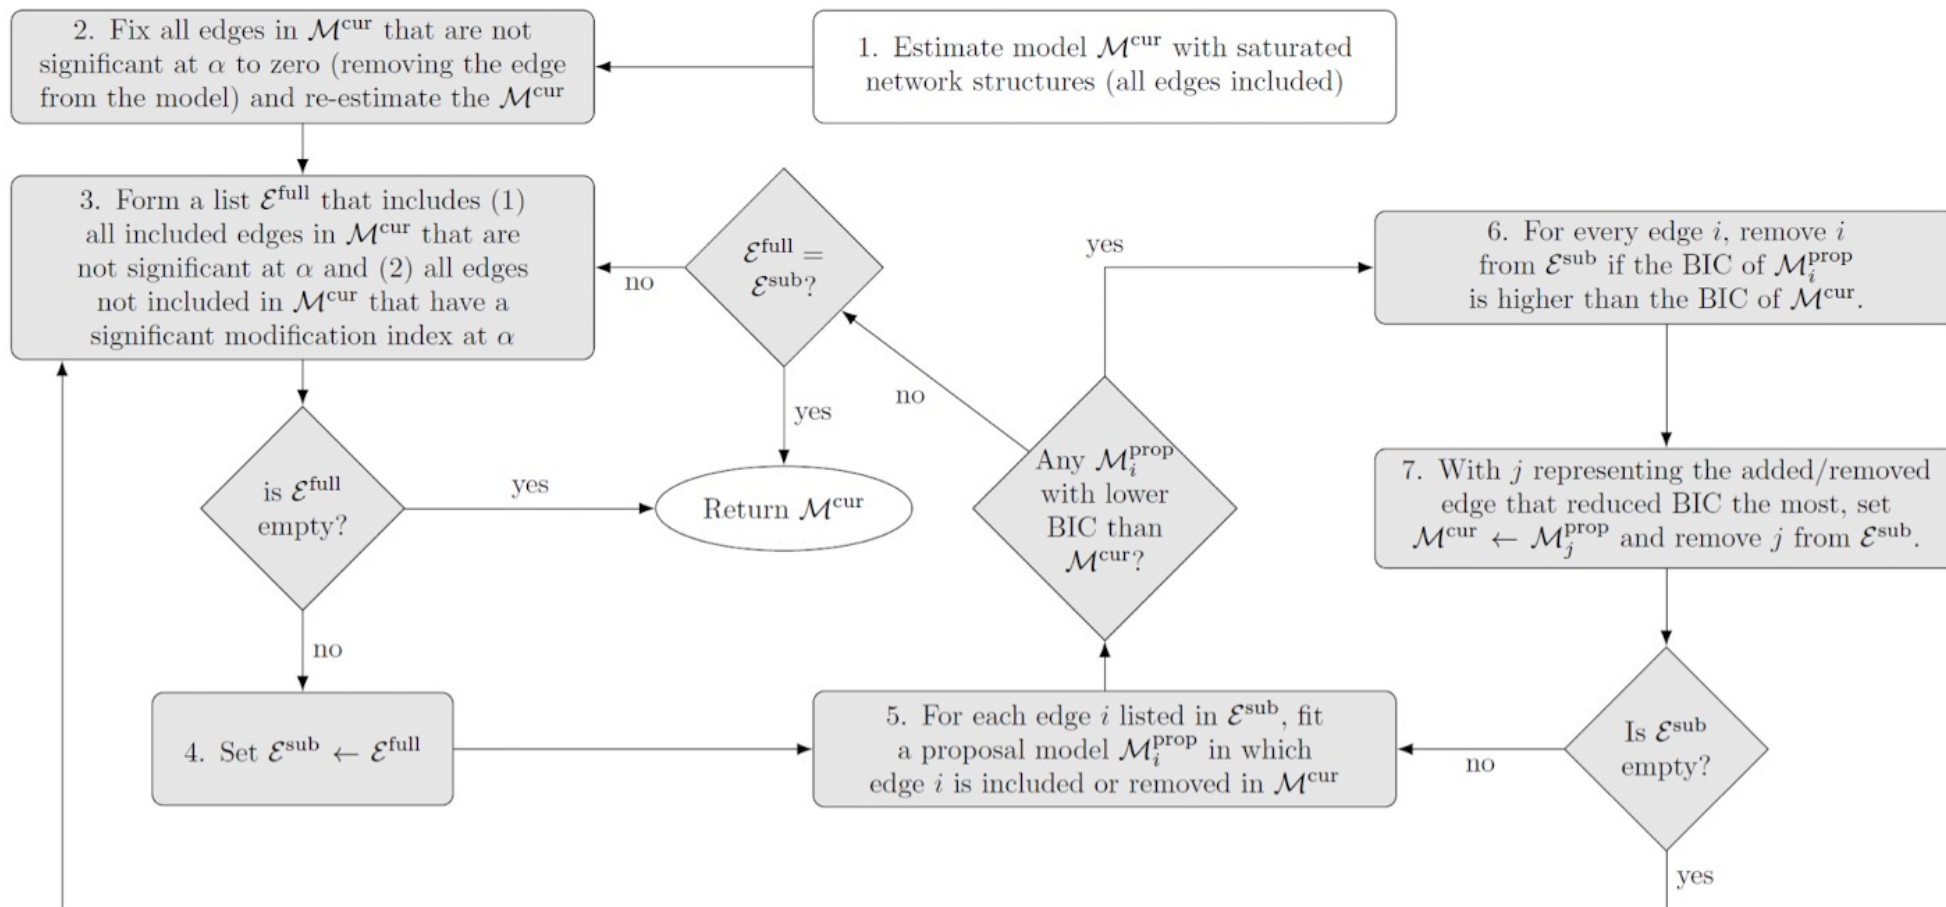

psychonetrics: modelsearch

- 先估计一个饱和模型
- 剪枝并重新估计模型M_cur
- 查看所有M_cur中不显著的edge以及MI显著的edge，将他们存进集合E_sub
- 将E_sub中的每一个edge依次在M_cur添加或删除，每次都重新估计模型，并查看BIC和MI
- 重复直到BIC不再下降，或者E_sub不再更新

```
mod <- ggm(bfi_na.rm) %>%  
runmodel %>% prune(alpha = 0.01)  
%>% modelsearch
```

```
net <- getmatrix(mod, "omega")
```

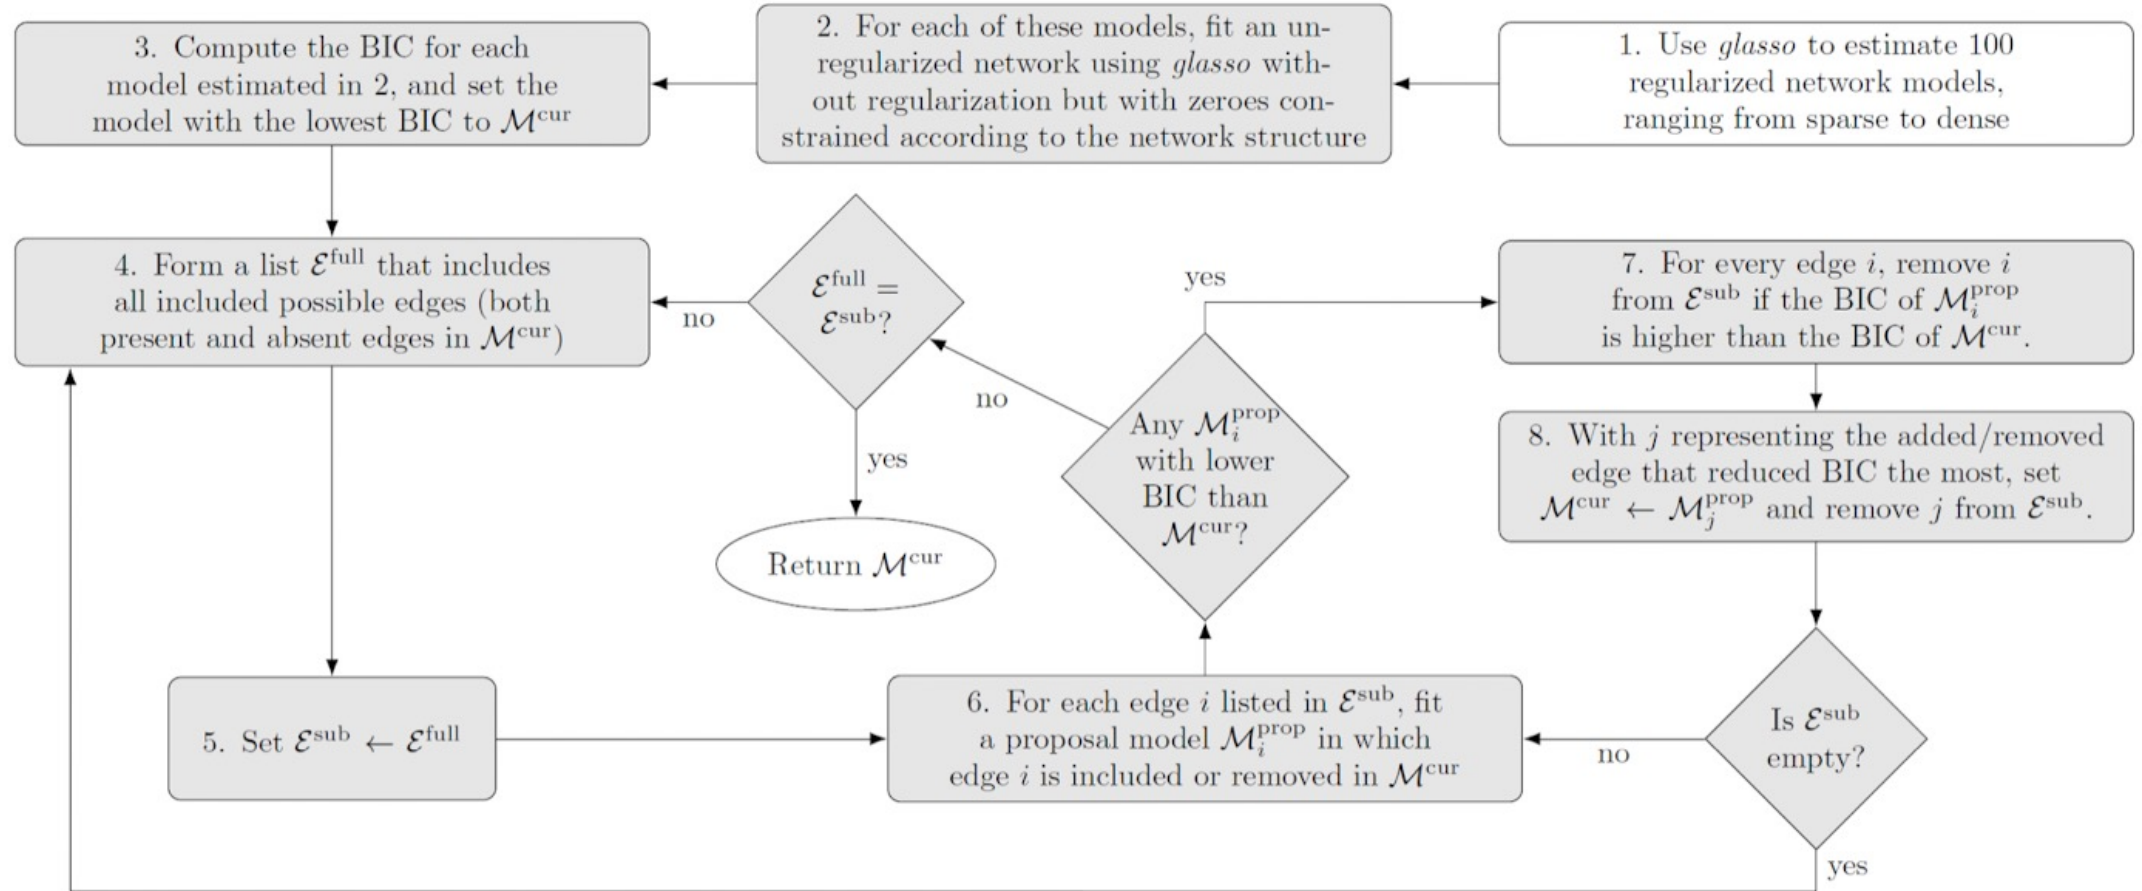
The modelsearch algorithm (psychometrics)



qgraph: ggmModSelect

- 与modelsearch相似，但是从正则化网络出发
- 先估计100个稀疏度不同的正则化网络
- 对每个正则化网络，用非正则方法重新估计一个网络，设置对应正则网络中为0的edge为0
- 选择这100个非正则网络中BIC最低的作为M_cur
- 将M_cur中每一个edge依次在M_cur添加或删除，每次都重新估计模型，并查看BIC
- 重复直到BIC不再下降或者M_cur不再改变

The ggmModSelect algorithm (qgraph)



```
net_ggmModSelect <- estimateNetwork(bfiSub, default = "ggmModSelect",
corMethod = "spearman")
```

总结

- 阈值/剪枝法
 - 将饱和模型中不合标准的edge隐藏 / 设置为0再重新估计
 - 好处：快速，有固定的假阳性率，无偏估计
 - 缺点：阈值法并不选择模型，小样本时不稳定，不一定能converge到真模型
- 正则法
 - 在最大似然中惩罚模型复杂度
 - 好处：快速，小样本时表现好，结果更易解释
 - 缺点：估计永远是biased的，大样本下表现不好
- 模型搜索
 - 依次添加或去除edge来优化某项指标（e.g., BIC）
 - 好处：同时照顾power和假阳性, 无偏估计，因为检查的模型多更可能converge到真模型
 - 坏处：很慢，小样本时表现糟糕

用哪个方法？

- 小样本使用regularized methods，大样本使用模型搜索
- Isvoranu, A.-M., & Epskamp, S. (2021). Which estimation method to choose in network psychometrics? Deriving guidelines for applied researchers. *Psychological Methods*.
<https://doi.org/10.1037/met0000439>

一些结语

心理网络的挑战

- 网络理论 \neq 网络模型
 - 什么网络模型最符合网络理论 is still a question
 - DAG? GGM?
- Collider effect
 - Beware of the negative edges
 - Berkson's bias
- What centrality in psychological networks is really?
- Causal inference with GGM is problematic, the corresponding causal generating mechanism of GGM is unknown (Ryan et al., 2022)
 - Other causal networks discovery algorithms without cyclic assumptions (Park et al., 2024)
 - Cyclic causal discovery (CCD) (Richardson, 1996b), fast causal inference (FCI) (Spirtes et al., 1995), and cyclic causal inference (CCI) (Strobl, 2019).

Endnote: 我们是否还需要潜变量模型

- 当然
 - 测量误差的估计无可替代
 - 需要更少的样本
 - IRT evaluation of item properties, information, item fit and person fit
 - Computer adaptive testing
 - Network模型仍在萌芽 功能尚不全面
 - 基于network的心理测量体系: Hudson Golino, Alexander P. Christensen
- 什么时候使用网络模型?
 - 无需潜变量假设的theory discovery tool
 - 当研究对象是可观测特征之间的（动态）关系时
 - 当有理论支撑可观测特征之间的因果关系时

小广告

- Twitter: @XinkaiDu
- Bluesky: @xinkaidu.bsky.social
- xinkai.du.xd@gmail.com
- 动态网络的比较
 - Du, X., Epskamp, S. (2024) Network comparison in time-series and panel data: The invariance partial pruning test. [Working Paper]
- 验证性网络分析及（动态）网络模型的拟合评估
 - Du, X., Freichel, R., Ebrahimi, O. V., Hoekstra, R. H. A., Skjerdingsstad, N., & Epskamp, S. (May, 2024). Moving from exploratory to confirmatory network analysis: An evaluation of SEM fit indices and cutoff values in network psychometrics. [Working paper].